

Phân tích các yếu tố quyết định độ "hit" của bài hát trên spotify (2023)

Câu hỏi nghiên cứu: Các chỉ số âm nhạc như độ nhảy hay năng lượng có tác động thuận chiều đến tổng lượt stream không?

Thành viên nhóm

 Bùi Công Huy

 Đào Minh Tuấn



Cơ sở và mô tả dữ liệu

Dataset

- Top Spotify Songs 2023 (Kaggle)
- Số lượng bản ghi ban đầu: **953 bài hát**
- Số lượng bản ghi sau làm sạch: **952 bài hát**
- Số lượng cột sử dụng trong phân tích: **25 biến**
- Tỷ lệ dữ liệu được giữ lại: $(952/953) \times 100\% \approx 99,9 \%$

Dataset chia thành 4 nhóm chính:

- 🎵 Thông tin bài hát (Song Information)
- 📈 Hiệu suất trên Spotify (Spotify Metrics)
- 🌐 Hiệu suất trên các nền tảng khác (Cross-platform Metrics)
- 🎧 Các đặc tính âm nhạc (Audio Features)

Tên biến	Vai trò trong mô hình
streams	Biến phụ thuộc
log_streams	Streams sau log
danceability_%	Biến độc lập
energy_%	Biến độc lập
artist(s)_name	Biến phân loại
released_year	Biến thời gian

Mục tiêu của nghiên cứu: tìm hiểu các yếu tố âm nhạc có ảnh hưởng như thế nào đến tổng lượt nghe (streams) của bài hát trên Spotify.

Data Cleaning & Data Preprocessing

Trước khi phân tích, dữ liệu được làm sạch thông qua các bước:

Làm sạch dữ liệu bị
lỗi trong các cột từ
các nền tảng khác

Sửa lỗi định dạng
và ép kiểu dữ liệu
cho cột 'streams'
và tạo log_streams

Row Dataset
953 rows

Xử lý dữ liệu văn
bản và xử lý trùng
lặp

Xử lý giá trị thiếu
cho cột phân loại
'key'

Kiểm tra và xử lý
các giá trị thiếu
trong các cột phân
tích chính

Cleaned Dataset
(952 rows, 25
columns)





Sau quá trình làm sạch, bộ dữ liệu đảm bảo tính nhất quán và phù hợp cho việc phân tích thống kê.

Phân Phối Streams vs Phân Phối Log Streams




- Streams có phân phối **lệch phải mạnh** (skewness ≈ 2.00).
- Sau biến đổi $\log_{10}$, log_streams phân bố cân đối hơn và phù hợp hơn cho mô hình hóa (mặc dù dữ liệu vẫn còn **lệch trái nhẹ** (skewness ≈ -1.19))



Xác định các bài hát siêu hit




- Boxplot cho thấy phân phối lượt stream **lệch mạnh với nhiều outliers ở phía trên whisker**.
- Điều này phản ánh sự tồn tại của một nhóm “**super hits**” có lượt nghe vượt xa phần lớn bài hát còn lại. Kết quả cho thấy thị trường Spotify có mức độ phân hóa cao và thành công của bài hát **không phân bố đồng đều**.



Audio Features


Danceability và Energy có giá trị trung bình cao nhất (**khoảng 60–70%**), trong khi Acousticness, Instrumentalness và Speechiness ở mức thấp.



Features	Mean	Median
danceability_ %	66.98	69.0
energy_ %	64.27	66.0
valence_ %	51.41	51.0

- Điều này cho thấy các bài hát trong tập dữ liệu Spotify Top Songs 2023 thường có nhịp điệu và năng lượng **cao hơn** các đặc tính mang tính nhạc cụ hoặc acoustic.
- Đồng thời, chênh lệch nhỏ giữa mean và median ở hầu hết các biến cho thấy dữ liệu **tương đối ổn định** và **ít bị ảnh hưởng** bởi ngoại lệ.

Audio Features vs Popularity




- Các biểu đồ phân tán cho thấy mối liên hệ **rất yếu** giữa danceability, energy và log_streams.
- Dữ liệu phân tán mạnh, các bài hit và không hit **chồng lấn trên** nhiều vùng giá trị, cho thấy hai đặc tính này **chưa đủ để giải thích** mức độ thành công của bài hát.


Ma trận tương quan toàn diện (correlation heatmap)



- Audio Features có tương quan **thấp-trung bình**
- Playlist Coverage giữa các nền tảng tương quan **khá cao**



Ít nguy cơ đa cộng tuyến giữa các Audio Features, nhưng cần cẩn trọng với các biến Playlist.



Phân tích tương quan (Correlation Analysis)



Mục tiêu: Kiểm tra mối quan hệ giữa các audio features và log_streams về chiều hướng, độ mạnh và ý nghĩa thống kê trước khi xây dựng mô hình OLS

- Pearson và Spearman đều cho thấy danceability và energy có **tương quan rất yếu** với log_streams ($|r|, |\rho| < 0.1$).
- Danceability có ý nghĩa thống kê nhưng **tác động âm**, trái với giả thuyết ban đầu; energy **không có ý nghĩa thống kê**.
- Kết quả sơ bộ cho thấy hai đặc tính này **khó giải thích mức độ thành công** của bài hát trên Spotify.

Kiểm định Pearson (Pearson Correlation)

Biến	r (Pearson)	p-value	Kết luận
danceability_%	-0.0689	0.0335	Tương quan yếu
energy_%	-0.0269	0.4070	Không có ý nghĩa thống kê

Kiểm định Spearman (Spearman Correlation)

Biến	ρ (Spearman)	p-value	Kết luận
danceability_%	-0.0817	0.0117	Tương quan yếu
energy_%	-0.0325	0.3169	Không có ý nghĩa thống kê



Mô hình OLS

$$\text{log_streams} = \beta_0 + \beta_1 * \text{danceability_}\% + \beta_2 * \text{energy_}\% + \varepsilon$$

Trong đó:

- β_0 là hằng số chặn;
- β_1, β_2 là các hệ số hồi quy biên tế;
- ε là sai số ngẫu nhiên

Kết quả


Biến	β	p-value
Danceability	-0.0052	0.046
Energy	-0.0010	0.677

$R^2 = 0.0049$

$\text{Adj } R^2 = 0.0028 \approx 0$

$\text{Prob(F-statistic)} \approx 0.096 > 0.05$

Kết luận sơ bộ



- Danceability có ý nghĩa thống kê nhưng tác động nghịch chiều
- Energy không có ý nghĩa thống kê
- Mô hình tổng thể không đạt ý nghĩa thống kê


Kiểm tra các giả định của mô hình hồi quy (OLS Assumption Checks)

1 Phân phối chuẩn của sai số

JB statistic	4876.0193
p-value	0.0000
Skewness	-1.2317
Kurtosis	13.8100

 Bác bỏ H0, sai số lệch khỏi phân phối chuẩn

2 Giả định về phương sai sai số không đổi (Homoscedasticity)




 Không thấy hiện tượng hình phễu

3 Kiểm tra đa cộng tuyến (Multicollinearity)

Biến	VIF
danceability_%	1.041012
energy_%	1.041012

 Hai biến độc lập không bị đa cộng tuyến đáng lo

 Mô hình **thỏa mãn tốt** giả định về đa cộng tuyến và phương sai đồng nhất. Dù sai số vi phạm phân phối chuẩn ($p = 0.0000$), nhưng với cỡ mẫu lớn ($N = 952$), định lý giới hạn trung tâm (CLT) đảm bảo kết quả hồi quy OLS vẫn **đáng tin cậy**

Mô hình phân lớp (Classification)



OLS thất bại vì mô hình tuyến tính hay vì dữ liệu?



Ý tưởng


Thay vì dự đoán chính xác số streams, chỉ dự đoán:

- Hit
- Non-Hit


Nếu danceability và energy thực sự quan trọng thì mô hình vẫn phải phân biệt được Hit và Non-Hit.

Kết quả

Metric	Value
Accuracy	56.6%
ROC-AUC	0.54



- **ROC-AUC $\approx$ 0.5:** gần như đoán ngẫu nhiên
- danceability và energy **không chứa nhiều tín hiệu dự báo**



Sự thất bại của OLS không đơn thuần xuất phát từ việc vi phạm giả định tuyến tính, mà là hệ quả trực tiếp từ việc hai biến độc lập chứa quá ít giá trị dự báo.

Đánh giá mô hình và kết quả nghiên cứu

? Danceability và Energy có giúp bài hát đạt nhiều stream hơn không ?



✗ KHÔNG

Dữ liệu Spotify 2023 không ủng hộ giả thuyết rằng các bài hát có Danceability và Energy cao sẽ đạt nhiều stream hơn.

Kết quả chính

⚠ **Danceability:** tác động nghịch chiều
✗ **Energy:** không có ý nghĩa thống kê


Các yếu tố có thể ảnh hưởng mạnh hơn

-  Marketing
-  Viral TikTok
-  Danh tiếng nghệ sĩ
-  Playlist Editorial
-  Fanbase

★ Thành công của bài hát phụ thuộc nhiều hơn vào các yếu tố ngoài âm nhạc

Conclusion & Business Insights

Conclusions



Audio Features không phải là yếu tố quyết định thành công của bài hát trên Spotify 2023

Business insights

Artist / Producer

Không tồn tại "công thức âm nhạc" đảm bảo hit.

Record Labels

- Cần kết hợp:
 - Audio Features
 - Marketing
 - Social Buzz
 - Playlist Reach
- Future Work
 - Thêm Artist Popularity
 - Genre
 - Playlist Count
 - Non-linear Models